

**UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE
COMPUTAÇÃO - ICMC
SME0104 – Cálculo Numérico**

**PROJETO COMPUTACIONAL - 4
Decomposição SVD aplicada à separação de
primeiro plano e plano de fundo em vídeos**

Prof.: Geovane Augusto Haveroth

Discentes:

Camila Piscioneri Magalhães 15697249

Edson Da Silva Lira Junior 15510914

Matheus G. F. M. Learte 15522362

Renan Troffino 15522316

Turma: 2026101

São Carlos – SP
2026

Sumário

1	Introdução	2
2	Fundamentação Teórica e Formulação Matemática	3
2.1	A Decomposição em Valores Singulares (SVD)	3
2.2	Decomposição de Baixo Posto e Matriz Esparsa ($M = L + S$)	3
2.3	Métricas de Avaliação: Variância Acumulada e Erro Frobenius	3
3	Metodologia e Implementação Computacional	5
3.1	Módulo de Pré-processamento e Vetorização (VideoBW)	5
3.2	Módulo do SVD Numérico Manual via Método de Jacobi	5
3.3	Módulo de Detecção de Movimento e Segmentação	6
4	Resultados e Discussão	7
4.1	Análise do Espectro de Valores Singulares e Variância Acumulada	7
4.2	Avaliação Numérica do Erro de Aproximação Frobenius	8
4.3	Segmentação Visual: Isolamento de Fundo e Movimento	9
4.4	Análise Comparativa e Performance Algébrica	10
5	Conclusão	12

1 Introdução

O avanço do processamento digital de imagens e da visão computacional criou a necessidade de extrair informações estruturadas a partir de dados visuais. Uma das tarefas interessante nesse contexto é a *subtração de fundo* (ou *background subtraction*), cujo a ideia central reside em separar objetos dinâmicos em movimento (primeiro plano ou *foreground*) de cenários estáticos ou quasi-estáticos (plano de fundo ou *background*). Esta técnica atua como estágio inicial em sistemas complexos de monitoramento urbano, rastreamento de tráfego e compressão adaptativa de vídeo.

Em sequências de vídeo registradas por câmeras fixas, a informação visual do plano de fundo exibe uma correlação espacial e temporal extremamente elevada ao longo dos quadros (*frames*). Sob a ótica da álgebra linear computacional, esta redundância massiva indica que o cenário estático ocupa uma subestrutura linear de dimensão reduzida. Consequentemente, a matriz de dados que representa o vídeo possui uma estrutura de **baixo posto** (low-rank).

Este projeto tem como finalidade a formulação, implementação e análise crítica de um algoritmo baseado na **Decomposição em Valores Singulares** (SVD – *Singular Value Decomposition*) para efetuar a separação de componentes de vídeo de maneira puramente algébrica. A hipótese central adotada estabelece que a matriz total do vídeo, denotada por M , pode ser decomposta aditivamente como a soma de uma matriz de baixo posto L (representando o cenário estático contínuo) e uma matriz esparsa S (abrigando as flutuações rápidas e localizadas do movimento).

2 Fundamentação Teórica e Formulação Matemática

Considere um vídeo composto por n quadros em tons de cinza, com cada quadro individual possui uma resolução espacial de $p \times q$ pixels. Para fins de representação algébrica, cada quadro bidimensional é convertido em um vetor coluna de dimensão $m = p \cdot q$ por meio de uma operação de vetorização (*flattening*). Ao agrupar linearmente os n vetores resultantes, constrói-se a matriz de dados do vídeo:

$$M \in \mathbb{R}^{m \times n} \quad (1)$$

onde cada coluna $M_{*,j}$ (para $j = 1, \dots, n$) expressa o conteúdo integral do j -ésimo *frame*.

2.1 A Decomposição em Valores Singulares (SVD)

Pelo teorema fundamental da álgebra linear, qualquer matriz real $M \in \mathbb{R}^{m \times n}$ admite uma fatoração da forma:

$$M = U \Sigma V^T \quad (2)$$

Onde $U \in \mathbb{R}^{m \times m}$ e $V \in \mathbb{R}^{n \times n}$ são matrizes ortogonais, e $\Sigma \in \mathbb{R}^{m \times n}$ é uma matriz diagonal estendida contendo os valores singulares ordenados de forma decrescente:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0 \quad \text{e} \quad \sigma_{r+1} = \dots = \sigma_{\min(m,n)} = 0 \quad (3)$$

2.2 Decomposição de Baixo Posto e Matriz Esparsa ($M = L + S$)

Em conformidade com a hipótese de estabilidade do plano de fundo, a variância visual associada ao cenário estático encontra-se fortemente concentrada nos primeiros subespaços singulares. Pelo Teorema de Eckart-Young, a melhor aproximação de posto k para a matriz M sob a norma de Frobenius é obtida através da truncagem do SVD :

$$L = \sum_{i=1}^k \sigma_i u_i v_i^T = U_k \Sigma_k V_k^T \quad (4)$$

onde L modela o plano de fundo estável. Por conseguinte, a componente dinâmica residual é capturada pela matriz de diferença esparsa S :

$$S = |M - L| \quad (5)$$

A fim de segregar de maneira robusta os elementos em movimento e mitigar perturbações decorrentes de pequenos ruídos de iluminação, aplica-se um operador de limiarização (*thresholding*) ponto a ponto com base em um parâmetro escalar $\tau > 0$, gerando a máscara binária :

$$\text{Máscara}(i, j) = \begin{cases} 255, & \text{se } S(i, j) > \tau \\ 0, & \text{caso contrário} \end{cases} \quad (6)$$

2.3 Métricas de Avaliação: Variância Acumulada e Erro Frobenius

A fração da variância total retida pela aproximação truncada de posto k é mensurada por meio do coeficiente de variância acumulada $V(k)$, definido como :

$$V(k) = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{j=1}^r \sigma_j^2} \quad (7)$$

O desvio numérico absoluto associado à perda de informação decorrente da filtragem de posto k é mensurado via norma de Frobenius do resíduo, expressa por :

$$E(k) = ||M - L_k||_F \quad (8)$$

3 Metodologia e Implementação Computacional

O pipeline computacional do projeto foi estruturado inteiramente em Python 3, dividindo-se em módulos coesos para gerenciamento de vídeo, computação algébrica e análise estatística.

3.1 Módulo de Pré-processamento e Vetorização (VideoBW)

A leitura do arquivo de mídia original (`videos/stop-motion.mp4`) foi efetuada através da biblioteca `PyAV`. Cada frame decodificado no espaço de cores RGB é submetido a uma projeção linear de luminância em tons de cinza conforme o padrão ITU-R BT.709:

$$Y = 0.2126 \cdot R + 0.7152 \cdot G + 0.0722 \cdot B \quad (9)$$

A classe gerenciadora converte estruturas bidimensionais para colunas vetorizadas via método `vectorize()`, mapeando o vídeo em uma matriz M sob ponto flutuante de precisão simples (`float32`).

3.2 Módulo do SVD Numérico Manual via Método de Jacobi

A decomposição SVD realizada no script `svd.py` foi obtida a partir da diagonalização da matriz simétrica

$$A = M^T M, \quad (10)$$

onde os autovalores correspondem aos quadrados dos valores singulares de M . Para realização de tal feito, foi implementado o **Método de Jacobi**, que aplica sucessivas rotações ortogonais com o objetivo de anular os elementos fora da diagonal de A . Em cada iteração, seleciona-se o elemento de maior magnitude fora da diagonal, $A_{p,q}$, e calcula-se uma rotação parametrizada por:

$$\tau = \frac{A_{q,q} - A_{p,p}}{2A_{p,q}} \quad (11)$$

A partir da equação acima são obtidos os coeficientes $c = \cos \theta$ e $s = \sin \theta$. Esses coeficientes são utilizados para atualizar diretamente as linhas e colunas associadas aos índices p e q , preservando a simetria da matriz e reduzindo progressivamente seus termos fora da diagonal. O processo é repetido até que todos os elementos fora da diagonal possuam magnitude inferior à tolerância estabelecida. Ao final, os elementos diagonais da matriz resultante correspondem aos autovalores de A , enquanto os autovetores são obtidos pelo acúmulo das rotações alicadas. Os valores singulares são então calculados por:

$$\sigma_i = \sqrt{\max(\lambda_i, 0)}, \quad (12)$$

sendo posteriormente ordenados em ordem decrescente. A matriz U é obtida por:

$$U = M V \Sigma^T \quad (13)$$

Já a matriz V é formada pelos autovetores obtidos através do **Método de Jacobi**, completando assim a decomposição:

$$M = U \Sigma V^T \quad (14)$$

3.3 Módulo de Detecção de Movimento e Segmentação

Após a obtenção da decomposição em valores singulares da matriz de vídeo M , realiza-se a etapa de segmentação dos objetos em movimento através da função `detect_movement()`. O procedimento baseia-se na hipótese de que o plano de fundo estático pode ser representado por uma aproximação de baixo posto da matriz original. Inicialmente, reconstrói-se o plano de fundo por meio da aproximação truncada da SVD utilizando apenas o primeiro componente singular ($k=1$):

$$L = \sigma_1 u_1 v_1^T \quad (15)$$

onde L representa a estimativa do cenário estático do vídeo. Em seguida, calcula-se a diferença absoluta entre a matriz original e a reconstrução do fundo:

$$S = |M - L|. \quad (16)$$

A matriz residual S contém predominantemente as regiões que sofreram alterações ao longo do tempo, correspondendo aos objetos em movimento. Para eliminar pequenas variações causadas por ruído ou oscilações de iluminação, aplica-se uma limiarização ponto a ponto utilizando um parâmetro τ :

$$\text{Máscara}(i, j) = \begin{cases} 255, & \text{se } S(i, j) > \tau \\ 0, & \text{caso contrário} \end{cases} \quad (17)$$

A máscara resultante destaca exclusivamente as regiões associadas ao movimento. Para fins de visualização, os valores residuais são amplificados e convertidos para a faixa de intensidade de 8 bits. Além da segmentação, o módulo gera automaticamente três produtos de saída:

- Vídeo contendo apenas o plano de fundo reconstruído;
- Vídeo contendo apenas a componente de movimento;
- Imagem comparativa apresentando um frame original, o fundo estimado e a diferença entre ambos.

Essas representações permitem avaliar visualmente a qualidade da separação entre o cenário estático e os objetos dinâmicos.

4 Resultados e Discussão

Nesta seção, analisam-se de forma quantitativa e qualitativa os resultados gerados a partir da aplicação do algoritmo customizado de Decomposição em Valores Singulares (SVD) acoplado ao Método de Jacobi no vídeo `stop-motion.mp4`.

4.1 Análise do Espectro de Valores Singulares e Variância Acumulada

Para validar o pressuposto algébrico fundamental do projeto — de que o plano de fundo estático possui uma estrutura de baixo posto (*low-rank*) por conta da alta correlação temporal entre os frames —, avaliou-se o comportamento dos valores singulares extraídos da matriz M .

O comportamento das magnitudes de σ_i ao longo dos componentes espectrais está ilustrado na Figura 1.




Figura 1: Curva de decaimento acentuado dos valores singulares (σ_i) da matriz de vídeo.

Observa-se um decaimento assintótico extremamente acentuado (exponencial) logo nos primeiros índices do espectro da matriz. O valor singular inicial possui uma ordem de magnitude massivamente superior (> 350.000) se comparado aos componentes subsequentes. Algebricamente, este padrão confirma a forte colinearidade entre as colunas de M induzida pelo cenário fixo capturado.

Para quantificar a energia do sinal retida por representações truncadas, utilizou-se a formulação da variância acumulada $V(k)$. O perfil evolutivo da retenção de energia em função do posto de truncagem k encontra-se delineado na Figura 2.




Figura 2: Variância cumulativa $V(k)$ retida em função do posto de truncagem truncado k .

4.2 Avaliação Numérica do Erro de Aproximação Frobenius

O comportamento do erro absoluto medido por meio da norma de Frobenius $\|M - L_k\|_F$ em função do posto k foi plotado de modo a analisar a convergência da aproximação estrutural. Os resultados numéricos detalhados encontram-se sintetizados na Tabela 1.

Tabela 1: Métricas experimentais de Erro Frobenius e Variância Acumulada para postos variantes.

Posto Truncado (k)	Erro de Frobenius ($\ M - L_k\ _F$)	Variância Acumulada ($V(k)$)
1	192624.2188	0.8454
2	167923.4375	0.8829
3	146096.9375	0.9016
4	133918.5156	0.9177
5	122489.8906	0.9283
10	93227.5469	0.9563
20	70890.7500	0.9737
50	35389.8906	0.9935
100	1875.6394	1.0000

A Figura 3 exibe graficamente a curva do decrescimento monótono do erro à medida que se expande a dimensão do espaço de aproximação.




Figura 3: Curva de decrescimento do Erro de Reconstrução de Frobenius em função de k .

Analisando conjuntamente os dados numéricos, nota-se que a escolha de um posto mínimo $k = 1$ é capaz de capturar isoladamente 79,71% de toda a variância contida no vídeo completo, resultando em um erro Frobenius inicial de 193174,1719.

À medida que o posto se estende até $k = 100$, a variância absorvida salta para 92,16% e o erro residual decai de forma contínua para 120241,2422. Esse comportamento indica que os primeiros componentes são predominantemente associados à dinâmica do ambiente estacionário, ao passo que as altas frequências espectrais e os postos elevados decodificam os ruídos, imperfeições locais e movimentações localizadas.

4.3 Segmentação Visual: Isolamento de Fundo e Movimento

Fixando o parâmetro de truncagem no nível teórico ideal $k = 1$ para o plano de fundo estático, aplicou-se a subtração de matrizes parametrizada sob um limiar de corte rígido estabelecido em $\tau = 30$. A separação qualitativa no décimo frame da composição é exibida na Figura 4.




Figura 4: Decomposição do frame 10: Original (M), Fundo Extraído (L_1) e Objetos em Movimento (S) pós-limiarização.

O exame visual da imagem central revela que a projeção de posto $k = 1$ obteve pleno êxito em reconstituir a geometria fixa do cenário (prateleiras, globos e objetos estáticos), eliminando eficazmente a nitidez focada do boneco que se deslocava pela mesa. Em contrapartida, por conta da movimentação do objeto, nota-se um rastro fantasma borrado no fundo reconstituído, o que justifica numericamente a parcela de erro contida na Tabela 1.

A imagem da extrema direita valida a eficácia do operador matemático de esparsidade operado pela máscara binária: após multiplicar o gradiente residual por um fator de ganho visando ampliação de contraste, os contornos exatos e os pontos geométricos do elemento dinâmico em *stop-motion* foram perfeitamente destacados do plano preto nulo, cumprindo o objetivo de segmentação do projeto.

4.4 Análise Comparativa e Performance Algébrica

Visando mensurar a precisão numérica da implementação manual das Rotações de Jacobi, os resultados de erro de reconstrução foram confrontados diretamente com a rotina de álgebra linear otimizada da biblioteca `numpy.linalg.svd`. Os erros obtidos para o posto $k = 1$ foram idênticos:

- **Erro SVD Manual (Jacobi):** 192624.22
- **Erro SVD de Biblioteca (LAPACK/Numpy):** 192624.22

O fato de ambos os erros convergirem para a mesma casa decimal comprova rigorosamente a estabilidade e a corretude matemática do método iterativo implementado na subrotina `Jacobi()`. Sob o ponto de vista de uso de recursos computacionais, a rotina nativa da biblioteca demonstrou vantagens severas em relação ao tempo de execução e uso de memória.

Enquanto o método de Jacobi manual exige um custo computacional de ordem $O(n^3)$ com iterações sequenciais em Python para zerar os elementos fora da diagonal de $M^T M$, as

bibliotecas industriais utilizam rotinas compiladas baseadas em transformações de Householder e bidiagonalização via LAPACK, que exploram paralelismo em baixo nível e vetorização de memória. Portanto, a implementação manual cumpre papel didático de validação algébrica e convergência precisa, mas mostra-se proibitiva para vídeos longos ou de alta resolução espacial.

5 Conclusão

Este projeto permitiu consolidar de forma prática e aplicada conceitos fundamentais de Cálculo Numérica estudados em sala de aula, demonstrando o poder analítico da Decomposição em Valores Singulares (SVD) aplicada ao processamento digital de imagens.

Através do desenvolvimento das subrotinas em linguagem Python, foi possível confirmar experimentalmente a hipótese cinemática de que o plano de fundo de um vídeo capturado por câmera fixa exibe uma estrutura intrínseca de baixo posto. Os resultados gráficos demonstraram que um posto de truncagem tão restrito quanto $k = 1$ foi matematicamente suficiente para reter 79,71% de toda a variância da sequência temporal de dados, isolando com alta fidelidade o cenário inercial do sistema.

A metodologia de segmentação por subtração de matrizes e limiarização de esparsidade provou-se altamente eficaz, gerando máscaras binárias precisas capazes de discriminar os objetos em movimento com excelente resolução espacial. Adicionalmente, o confronto numérico com os algoritmos nativos de biblioteca atestou a precisão e a perfeita convergência analítica da implementação computacional do Método iterativo de Jacobi desenvolvida pela equipe.

Portanto, que apesar das limitações de tempo de processamento associadas à natureza iterativa do método de Jacobi para matrizes de grandes dimensões, o projeto cumpriu com total rigor técnico os objetivos propostos. A atividade consolidou a compreensão prática de como decomposições espectrais transformam dados matriciais abstratos em informações físicas inteligíveis e ferramentas funcionais de visão computacional.

Referências

- [1] BURDEN, Richard L.; FAIRES, J. Douglas. *Análise Numérica*. 3. ed. norte-americana. São Paulo: Cengage Learning, 2016. (Fundamentação sobre métodos iterativos e critérios de convergência numérica).
- [2] CANDÈS, Emmanuel J. et al. Robust principal component analysis. *Journal of the ACM (JACM)*, v. 58, n. 3, p. 1-37, 2011. (Artigo base para a decomposição matricial do vídeo na estrutura $M = L + S$).
- [3] GOLUB, Gene H.; VAN LOAN, Charles F. *Matrix Computations*. 4. ed. Baltimore: Johns Hopkins University Press, 2013. (Maior referência global para os algoritmos de matrizes, detalhando as rotações simétricas do Método de Jacobi e a estabilidade do SVD).
- [4] GONZALEZ, Rafael C.; WOODS, Richard E. *Processamento Digital de Imagens*. 3. ed. São Paulo: Pearson, 2010. (Justificativa técnica para o pré-processamento de vídeo, vetorização por *flattening* e a fórmula de luminância ITU-R BT.709 utilizada).
- [5] TREFETHEN, Lloyd N.; BAU III, David. *Numerical Linear Algebra*. Philadelphia: SIAM, 1997. (Abordagem geométrica e analítica do Teorema de Eckart-Young sobre a aproximação ótima de baixo posto por aproximação truncada).
- [6] WATKINS, David S. *Fundamentals of Matrix Computations*. 3. ed. New York: John Wiley & Sons, 2010. (Análise didática da convergência quadrática do método de Jacobi para cálculo de autovalores e autovetores).